

TEAM 10

근거를 먼저 찾고, 핵심을 빠뜨리지 않는 RAG

카카오 약관 질의응답 결과기 · 개선 과정과 평가 전략

93.915

공식 공개 연습 최고점

MRR 1.000

F1 0.808

LLM 99.350

Steve.Park(박상욱)
Sophia.Kim(김민지)

정답 생성보다 먼저, 올바른 원문을 찾아야 했습니다

검색 순위·핵심 내용·근거 기반 답변을 동시에 만족해야 하는 과제

01 RETRIEVAL

정답 조항을
앞 순위에 배치

MRR은 retrieved에서
첫 정답 조항의 순위를 평가

02 COVERAGE

핵심 사실을
빠짐없이 보존

수치·기간·예외·효력 누락은
키패트 F1을 직접 낮춤

03 GROUNDING

원문 밖 내용을
만들지 않기

정확성·근거성·완결성·명료성을
LLM 평가로 종합 판단

목표: 검색 정확도를 고정한 뒤, 누락과 환각을 줄이는 방향으로 실험했습니다.

검색은 정확도와 일반화를 함께 확보했습니다

어휘 일치와 의미 유사도를 결합한 하이브리드 Retriever

BM25

법률 용어 · 수치 · 서비스명

- 고유명사
- 정확한 표현이 겹칠 때
강하고 설명 가능한 기준선

BGE-M3

동의어 · 구어체 · 간접 표현

표면 단어가 달라도
의미적으로 가까운 조항 회수

RRF + 동적 Top-K

순위 결합 · 1~4개 근거

1등 대비 점수 낮은 후보 제거해
모델 혼동과 불필요한 문맥 감소

성과

공개 공식 평가에서 MRR 1.000을 유지하면서 생성 단계 개선을 분리해 검증

점수 상승은 '더 많이 생성'이 아니라 '근거에서 빠진 것만 보완'한 결과입니다

Qwen 생성과 제한적 후처리

01 — 근거 집중

선택 조항과 질문 관련 원문 구절을
함께 제공해 읽어야 할 범위를 좁힘

02 — 핵심 보존

1위 원문에 실제로 있는 조건·효력만
누락 시 보완해 환각 경계를 유지

03 — 출력 정리

목록 번호·장식 따옴표·불필요한 줄바꿈을
자연스러운 한국어 답변으로 정리

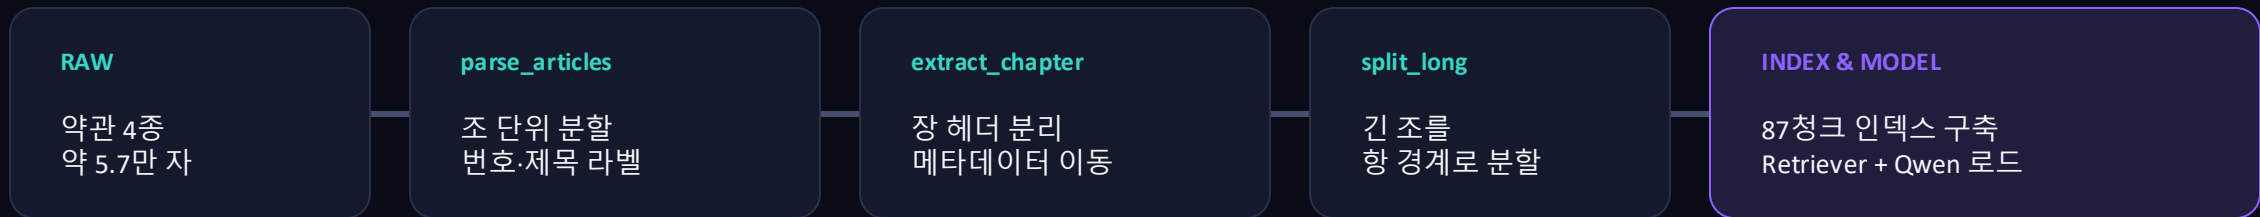
핵심 원칙

후처리는 정답을 새로 만드는 단계가 아니라 원문에 존재하는 누락 사실을 복구하는 안전장치입니다.

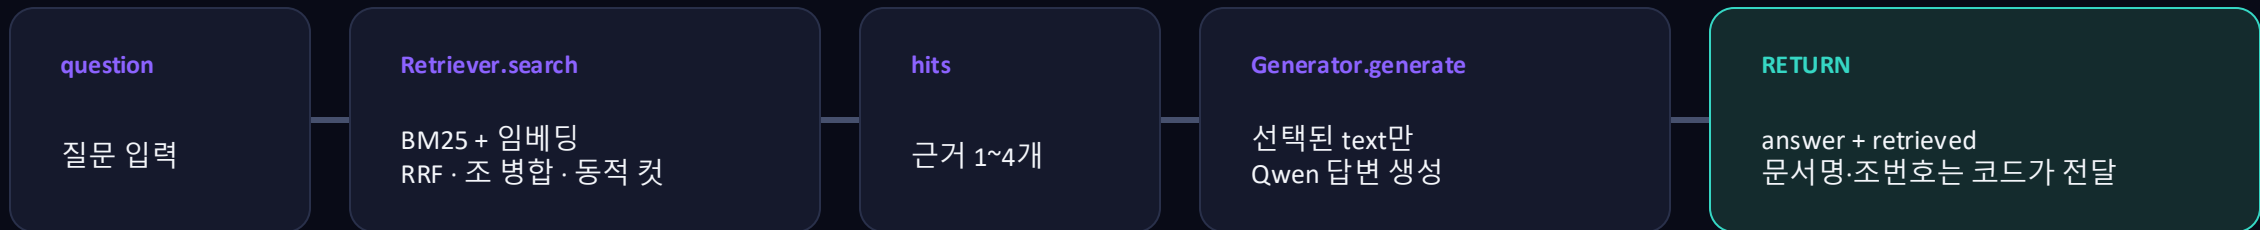
초기화는 한 번, 검색과 생성만 질문마다 반복합니다

모델 로딩과 인덱스 구축을 질의 경로 밖으로 분리

INITIALIZE · 셀 실행 시 1회



QUERY · 질문마다 반복



4개 문서 · 72개 조 · 87개 청크

retrieved는 LLM을 거치지 않아 조번호 환각을 구조적으로 차단

공개 MRR 만점 이후, 병목은 ‘검색’보다 ‘답변 완결성’이었습니다

평가 지표를 개선 우선순위로 변환

검색 품질

MRR 1.000

공개 문항에서 이미 만점

유지할 것

정답 조항 Top-1 · retrieved 문서명

→ 검색 회귀를 막고 생성 품질에 집중

생성 품질

누락 · 모순 · 과잉 설명

F1과 LLM 평가에서 반복적으로 드러난 문제

핵심 명사·수치

원문 표현 보존

조건·예외·효력


복합 요구 누락 방지

근거 밖 부연

환각·중복 억제

한 번에 하나를 바꾸고, 문항별 회귀를 통과해야 채택했습니다

평균 점수만 보지 않는 비교 절차




채택 기준

총점 상승 + 기존 정답 방향 유지 + 새 환각 없음

속도는 품질 게이트를 통과한 후보끼리 비교

MRR을 지키면서 총점을 5.724점 끌어올렸습니다

공식 공개 연습 평가 · 시험 24 → 39



88.191 → 93.915 · 상대 +6.49%

무엇이 바뀌었나

24 → 28 누락 핵심 원문을
제한적으로 보완 +1.088

28 → 37 출력 형식을 자연
스러운
단일 문단으로 정
리 +2.753

37 → 39 P07·P10 결론절을
1위 원문에서만 보
완 +1.883

빠른 모델과 강한 지시가 항상 더 좋은 답을 만들지는 않았습니다

실패를 다음 실험의 경계로 사용

01	3B 모델	P08 결론 역전 · P04/P10 환각 및 반복	속도보다 함정 교정과 복합 근거 종합이 중요
02	판단 절차 강제	P08은 교정됐지만 전역 출력 품질 저하	좋은 규칙도 적용 범위가 넓으면 전체 품질을 해침
03	질문 명사 가중	P09 법적 관계가 반대로 생성	키워드 노출 자체가 작은 모델의 결론을 끌 수 있음
04	관련 문장 축소 실험	P10에서 제출 절차는 찾았지만 동의 효력 누락	질문과 직접 겹치는 문장뿐 아니라 같은 조항의 조건·효력까지 함께 전달해야 함

속도는 측정했지만, 점수에 들어가는 품질을 먼저 선택했습니다

빠른 오답보다 안정적인 정답을 우선한 판단

3B FP16

P50 8.90초

실험 8의 7B 대비 32.56% 단축

하지만 **P08 정답 역전 · P10 효력 누락**

→ 품질 게이트 실패로 최종 폐기

7B NF4 + 동적 Top-K

P50 13.20초

고정 Top-4 대비 P50-P95 약 16% 개선

동시에 **정답 근거 12/12 · P05 개선**

→ 품질을 지키며 빨라져 최종 기반으로 채택

예선 응답시간은 기록되지만 점수에는 직접 반영되지 않음

평가기까지 직접 만들어 답변의 강점과 남은 위험을 교차 확인했습니다

결과기와 평가기의 판단 기준을 연결

실제 확인

후보 5개 × 공개 10문항

Gemini 순차 평가 · 체크포인트 재사용

BLIND01	BLIND02	BLIND03	BLIND04	BLIND05
96.676	94.839	100.000	93.989	97.320

남은 한계와 다음 개선

- | | | |
|----|----------------|----------------------------|
| 01 | 공개 10문항 과적합 위험 | 비공개 30문항으로 회귀·일반화 검증 |
| 02 | 후처리 규칙의 적용 범위 | 문항 유형별 오탐과 과잉 보완 점검 |
| 03 | 평가기의 Gemini 의존 | API 실패·판정 불가·입력 오류 사전검사 강화 |

평가기 점수는 공식 결과기 점수가 아닌, 설계 검증용 교차 평가

평가기 역시 근거·핵심 내용·답변 품질을 분리해 계산합니다

후보별 0~100 원점수만 기록하고 순위는 운영진이 계산

10 점

MRR

정답 문서·조항의
최초 등장 순위

20 점

키팩트 F1

내용 토큰의
정밀도와 재현율

70 점

Gemini LLM

정확성 40% · 근거성 25% · 완결성 20% · 명료성 15%

평가 흐름

question
10~50문항

terms
약관 4종

blind
후보 5개

Gemini
순차 평가

eval_10.json
점수·상태

completed · partial · failed

CONCLUSION

검색 만점을 지키고, 누락을 줄여 93.915점을 만들었습니다.

핵심은 더 복잡한 모델이 아니라, 실패 원인을 검색·생성·후처리로 분리하고 원문에 존재하는 사실만 단계적으로 복구한 실험 과정이었습니다.

RETRIEVE

BM25 + Dense + RRF로 정답 조항을 앞에

GENERATE

Qwen 7B가 선택된 근거 안에서 답변

VERIFY

누락만 제한/보완하고 환각은 차단